databricks

# Guia compacto de Data Engineering

# Conteúdo


## Introdução à engenharia de dados na Databricks 3

## Orientações e práticas recomendadas 16

Migrar cargas de trabalho ETL do Apache Spark™ para Databricks 17

## Estudos de caso 22

NFCU: usando dados em tempo real para inovar na personalização de membros 23

Cincinnati Reds: vencendo dentro e fora do campo com análises de beisebol de ponta 27

# 01

# Introdução à Engenharia de Dados na Databricks

# Introdução à engenharia de dados na Databricks

À medida que o volume de dados continua a crescer e a complexidade das fontes e da distribuição se intensifica, as organizações têm dificuldade em manter o controle e em extrair valor deles de forma eficaz. De acordo com uma pesquisa recente da IDC sobre avaliação de dados, 41% das organizações responderam que os dados estão mudando mais rápido do que elas conseguem acompanhar. Somado à crescente pressão para capitalizar em IA, organizações de todos os setores enfrentam novos desafios  que precisam superar para se manterem competitivas em seus respectivos campos. Muitas delas, ao disputar essa corrida pelos dados, acabam se deparando com a mesma dura realidade:

***Tudo, desde IA até analytics, BI e aplicações, começa com bons dados.***

Essa realidade enfatiza a importância de criar pipelines confiáveis que possam ingerir ou processar streams de grandes volumes de dados com eficiência e garantir a alta qualidade desses dados, de forma confiável e em grande escala. Uma plataforma unificada e uma boa engenharia de dados são componentes essenciais para o sucesso em qualquer iniciativa de analytics, business intelligence (BI) e IA. Com a solução certa de engenharia de dados, as organizações podem transformar seus dados proprietários em ativos comerciais reais e, ao mesmo tempo, aproveitar esses insights de negócios para criar seus aplicativos e fluxos de trabalho agênticos.

Este livro oferece orientações práticas, padrões úteis, melhores práticas e exemplos do mundo real para ajudá-lo a entender como os engenheiros de dados podem enfrentar os desafios desta nova era e como a Databricks Data Intelligence Platform pode apoiá-lo em sua jornada.

## O que é a engenharia de dados?

A engenharia de dados é a prática de extrair dados brutos de uma fonte e processá-los para armazenamento e organização em um caso de uso posterior, como análise de dados, Business Intelligence (BI) ou treinamento de modelos de machine learning (ML). Em outras palavras, é o processo de preparar dados para que se possa extrair valor deles.

Uma forma prática de enxergar a engenharia de dados é usar a seguinte estrutura, que inclui três partes principais:

1. **Ingerir**
   A ingestão de dados é o processo de trazer dados de uma ou mais fontes para uma plataforma. Essas fontes podem ser arquivos armazenados no local ou em serviços de armazenamento em nuvem, bancos de dados, aplicativos e, cada vez mais, streams de dados que produzem eventos em tempo real.
2. **Transformar**
   A transformação de dados pega dados brutos ingeridos e usa uma série de etapas (chamadas de "transformações") para filtrá-los, padronizá-los, limpá-los e, finalmente, agregá-los para que sejam armazenados de forma utilizável. Um padrão popular é a arquitetura medallion, que define três estágios no processo — Bronze, Prata e Ouro.
3. **Orquestrar**
   A orquestração de dados se refere à forma como um pipeline de dados que realiza a ingestão e a transformação é agendado e monitorado, bem como ao controle das várias etapas do pipeline e como ele lida com as falhas (por exemplo, executando uma nova tentativa).

## Desafios da engenharia de dados na era da IA

Como mencionado anteriormente, a engenharia de dados é fundamental para garantir dados confiáveis para iniciativas de IA, analytics e BI. Engenheiros de dados que constroem e mantêm pipelines de ETL e a infraestrutura de dados que suporta workloads de analytics e IA enfrentam desafios específicos neste cenário em rápida evolução.

- **Fontes de dados dispersas desafiam a maioria das organizações:** a ISG prevê que, até 2026, 8 em cada 10 empresas terão seus dados distribuídos por vários provedores de nuvem e data centers locais que abrangem múltiplas localizações. Essa descentralização cria uma dependência de equipes especializadas e isoladas, pipelines ineficientes, desenvolvimento com altos custos e tempo de retorno lento. Como resultado, o uso dos dados é limitado e a inovação fica comprometida.
- **Ferramentas fragmentadas:** a maioria das empresas depende de várias ferramentas e serviços externos ou soluções internas personalizadas para gerenciar seus processos de ETL. Essas ferramentas geralmente são desconexas, com arquiteturas, interfaces e saídas distintas, o que adiciona mais uma camada de complexidade à experiência de engenharia de dados e leva a gargalos nas equipes.
- **Gerenciamento de dados em tempo real:** de aplicativos móveis a dados de sensores em linhas de produção, um volume cada vez maior de informações é gerado e transmitido em tempo real, exigindo processamento de baixa latência para viabilizar a tomada de decisões imediatas.
- **Escalando pipelines de dados de forma confiável:** com o aumento do volume de dados, muitas vezes em tempo real, escalar a infraestrutura de processamento que executa os pipelines torna-se um desafio, especialmente ao tentar manter os custos baixos e a performance alta. Garantir a execução confiável dos pipelines, monitorá-los e solucionar falhas são algumas das principais responsabilidades dos engenheiros de dados.
- **Qualidade dos dados:** “garbage in, garbage out” ("entra lixo, sai lixo"). A alta qualidade dos dados é essencial para treinar modelos precisos e obter insights acionáveis. Garantir tal qualidade é um desafio fundamental para os engenheiros de dados.
- **Governança e segurança:** a governança está se tornando um desafio crucial para as organizações que encontram seus dados distribuídos por vários sistemas, com um número crescente de equipes internas buscando acessá-los e utilizá-los para diferentes propósitos. Proteger e governar os dados também é uma preocupação regulatória significativa que muitas organizações enfrentam, especialmente em indústrias altamente regulamentadas.

Esses desafios destacam a importância de escolher a plataforma de dados adequada para atender às necessidades em constante evolução, especialmente na era da IA. Mas uma plataforma de dados nesta era pode ir além de simplesmente lidar com os desafios de construção de soluções de IA. A plataforma certa pode melhorar a experiência e a produtividade dos profissionais, incluindo engenheiros de dados, ao incorporar inteligência e usar IA para auxiliar nas tarefas diárias de engenharia.

Em outras palavras, a nova plataforma de dados é uma plataforma de *inteligência* de dados.

## A Databricks Data Intelligence Platform

A missão da Databricks é democratizar dados e IA, permitindo que as organizações utilizem seus dados únicos para desenvolver ou aperfeiçoar seus próprios modelos de machine learning e IA generativa, gerando novos insights que conduzam à inovação empresarial.

A Databricks Data Intelligence Platform é construída sobre a arquitetura lakehouse, oferecendo uma base aberta e unificada para todos os dados e governança, e é impulsionada por um mecanismo de inteligência que compreende as particularidades dos seus dados. Com essas capacidades como fundamento, a plataforma permite que os clientes da Databricks executem uma variedade de workloads, desde business intelligence e data warehousing até IA e ciência de dados.

Para entender melhor a Databricks Platform, a próxima página mostra uma visão geral das diferentes partes da arquitetura em relação à engenharia de dados. A Databricks Data Intelligence Platform permite que você execute todas as suas iniciativas de dados, analytics, BI e IA. Como uma plataforma 100% serverless, ela oferece recursos integrados, como recuperação de desastres, controles de custos e segurança empresarial. Componentes-chave incluem o Mosaic AI, com IA de ponta a ponta para IA generativa e clássica; o Databricks SQL, um data warehouse serverless inteligente; engenharia de dados unificada com Lakeflow, um banco de dados integrado com Lakebase; e AI/BI que se integra profundamente ao Databricks SQL para ampliar a inteligência de negócios em toda a sua empresa.

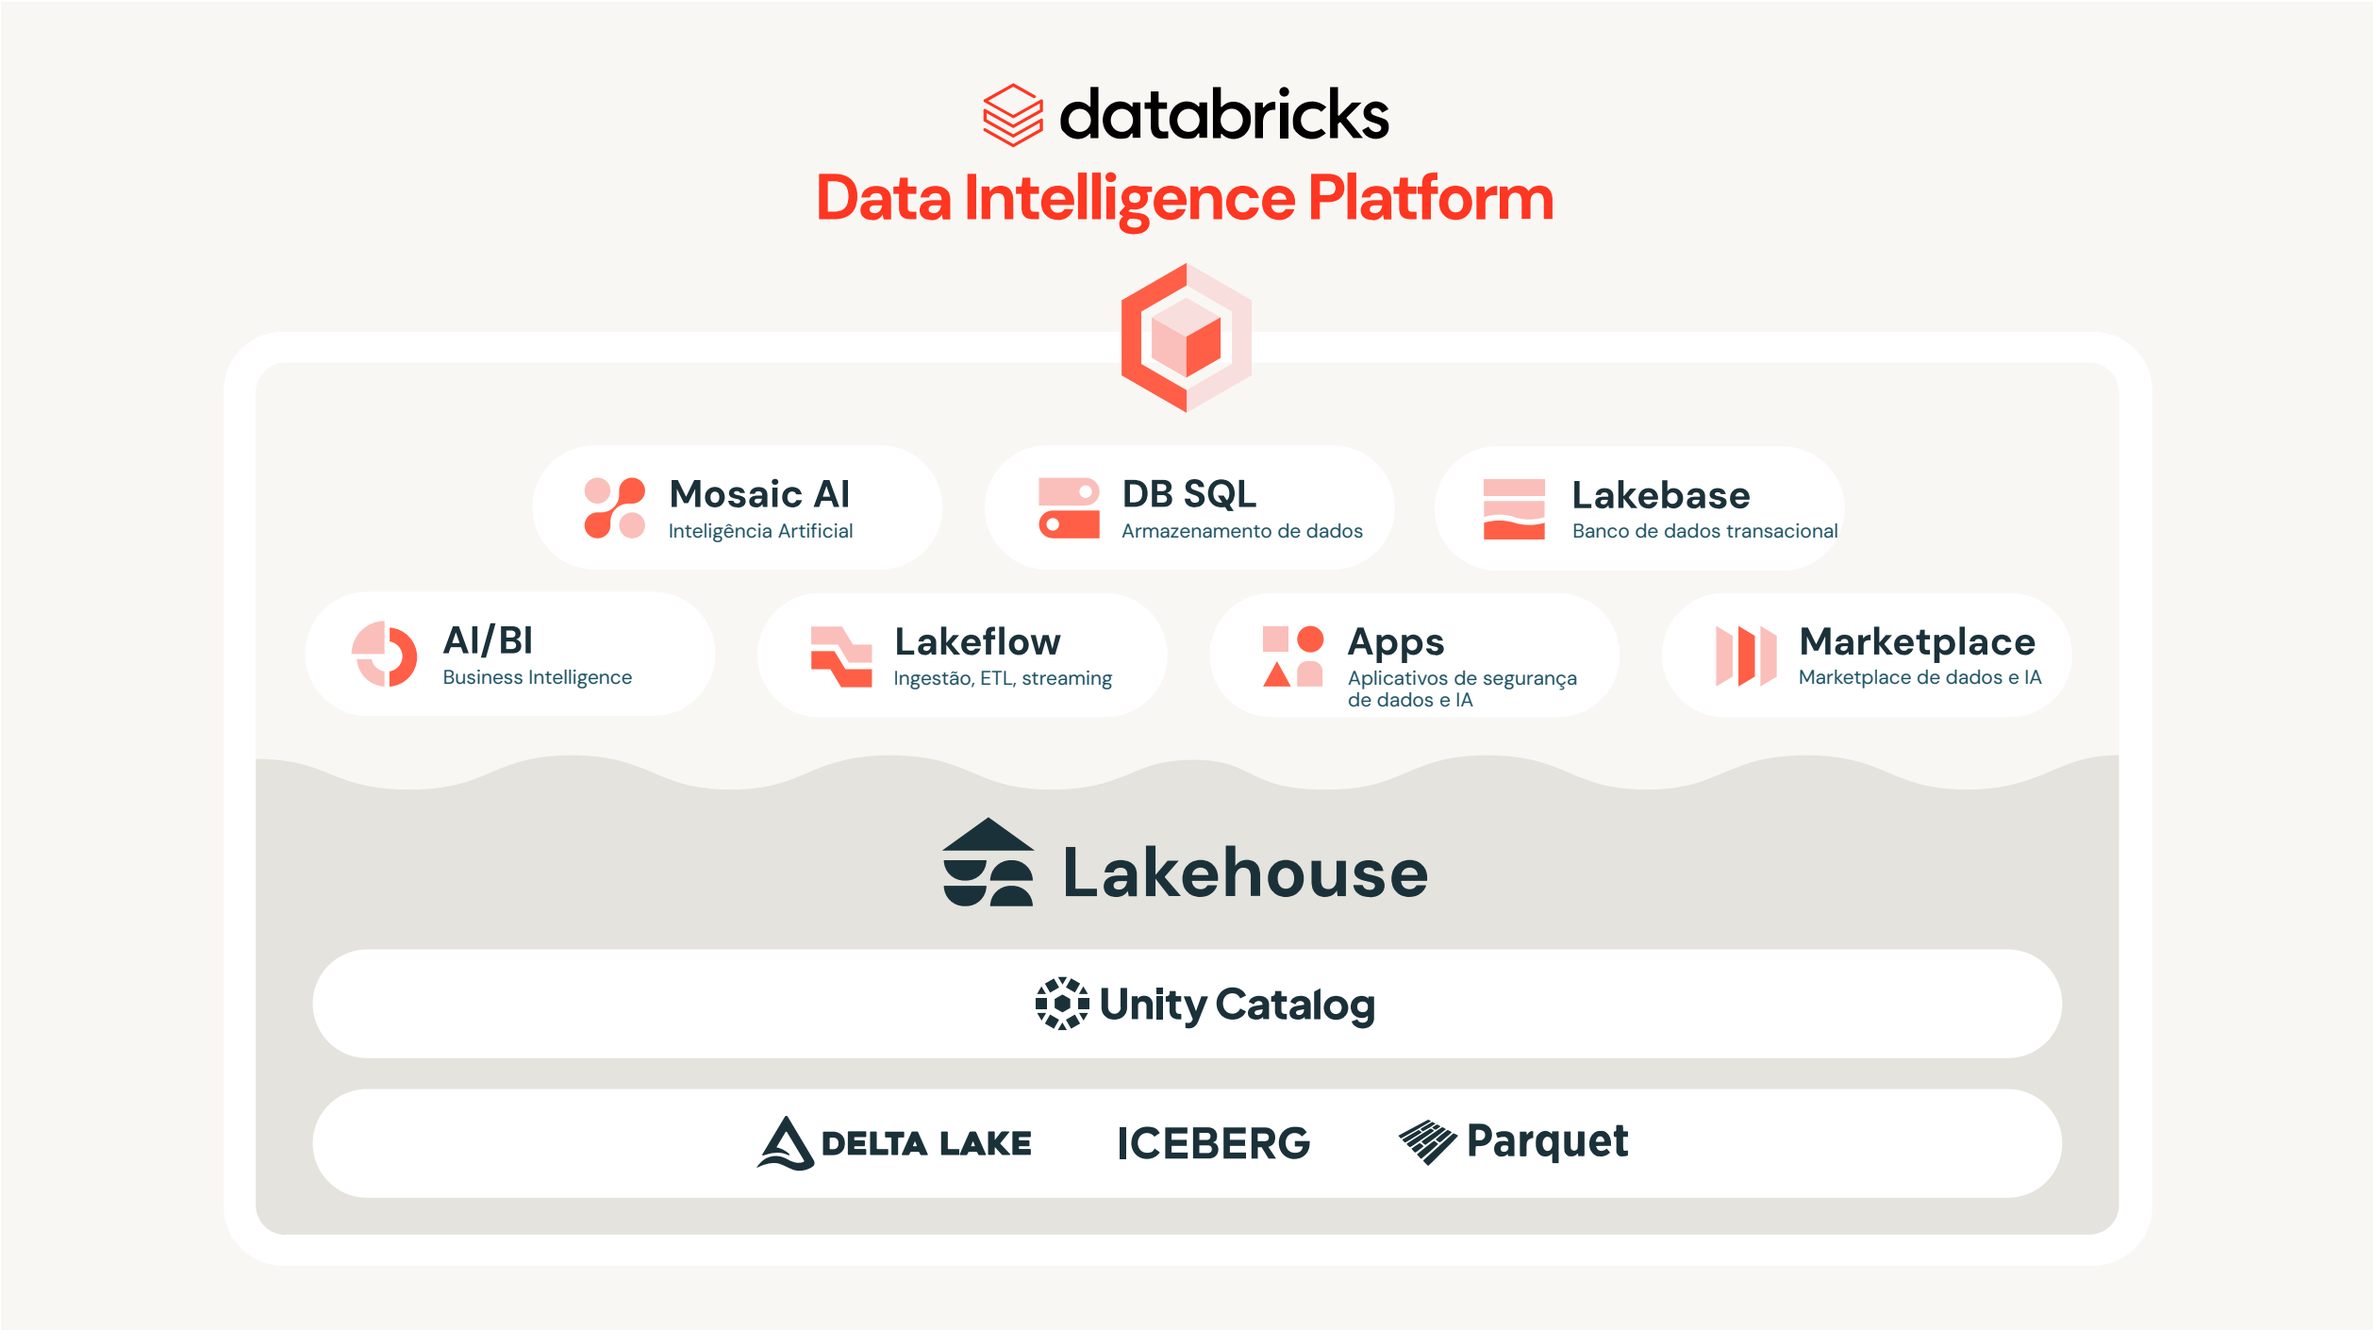
databricks
Data Intelligence Platform
Mosaic AI
Inteligência Artificial
DB SQL
Armazenamento de dados
Lakebase
Banco de dados transacional
AI/BI
Business Intelligence
Lakeflow
Ingestão, ETL, streaming
Apps
Aplicativos de segurança de dados e IA
Marketplace
Marketplace de dados e IA
Lakehouse
Unity Catalog
DELTA LAKE
ICEBERG
Parquet

Vários elementos da Data Intelligence Platform são particularmente importantes para os engenheiros de dados e merecem uma análise mais detalhada. A próxima seção abordará o Lakeflow — a solução unificada de engenharia de dados para ingestão, transformação e orquestração. Mas, antes disso, vale a pena entender as partes fundamentais da plataforma que fornecem um valor importante para os engenheiros de dados:

## GOVERNANÇA UNIFICADA E ABERTA COM O DATABRICKS UNITY CATALOG

O Unity Catalog (UC) oferece um catálogo de dados único e centralizado para gerenciar permissões, auditoria e linhagem em todos os ativos de dados e IA na lakehouse. Ele é compatível com os principais formatos abertos, incluindo Delta Lake, Apache Iceberg™, Hudi e Parquet, permitindo que os engenheiros escolham o formato mais adequado para os seus workloads, sem ficarem presos a um único formato. Com controles de acesso integrados, monitoramento da qualidade dos dados e linhagem em nível de coluna, o Unity Catalog facilita a aplicação de conformidade e confiança, ao mesmo tempo em que acelera o desenvolvimento. A interoperabilidade entre formatos e o compartilhamento seguro de dados por meio do Delta Sharing garantem que os engenheiros possam colaborar entre equipes, plataformas e nuvens, mantendo uma governança consistente. O Unity Catalog reduz a complexidade, escala de acordo com as necessidades das plataformas de dados modernas e mantém a abertura e a confiabilidade como base para todos os fluxos de trabalho de engenharia de dados.

## ACELERANDO A PRODUTIVIDADE COM O DATABRICKS ASSISTANT

A Databricks combina a IA generativa com os benefícios de unificação de um lakehouse para alimentar um mecanismo de inteligência de dados que entende a semântica exclusiva de seus dados. Isso permite que a Databricks Platform otimize automaticamente o desempenho e gerencie a infraestrutura de forma exclusiva para sua empresa. Construído sobre esse mecanismo está o Databricks Assistant — um assistente de IA com reconhecimento de contexto que oferece uma API de conversação para executar uma query de dados, gerar código, explicar queries de código e até mesmo corrigir problemas. O Databricks Assistant ajuda os profissionais, incluindo engenheiros de dados, a se tornarem mais produtivos, reduzindo o tempo necessário para criar novos pipelines de dados e solucionar problemas de pipeline.

## BANCO DE DADOS INTEGRADO E PRONTO PARA IA COM O LAKEBASE

Todos os aplicativos são executados em um banco de dados e o Postgres é o banco de dados preferido pela maioria dos desenvolvedores de aplicativos. O Databricks Lakebase é um banco de dados Postgres totalmente gerenciado e integrado no lakehouse para facilitar a criação de aplicativos de dados e IA. O Lakebase sincroniza automaticamente os dados do lakehouse e os recursos/modelos em um banco de dados operacional para aplicativos de baixa latência, painéis e sistemas de CRM. Com o Lakebase, as equipes de engenharia podem se concentrar em fornecer insights para os aplicativos em vez de construir pipelines personalizados, gerenciar infraestrutura ou administrar bancos de dados.

## UM ECOSSISTEMA ROBUSTO DE SOLUÇÕES DE DADOS

A Data Intelligence Platform é construída com tecnologias de código aberto e adota padrões abertos, permitindo que as principais soluções de dados sejam aproveitadas em qualquer coisa que você construa no lakehouse.

Uma grande coleção de parceiros de tecnologia facilita e simplifica a integração de tecnologias das quais você depende ao migrar para a Databricks — e você não fica preso a uma pilha fechada de tecnologia de dados.

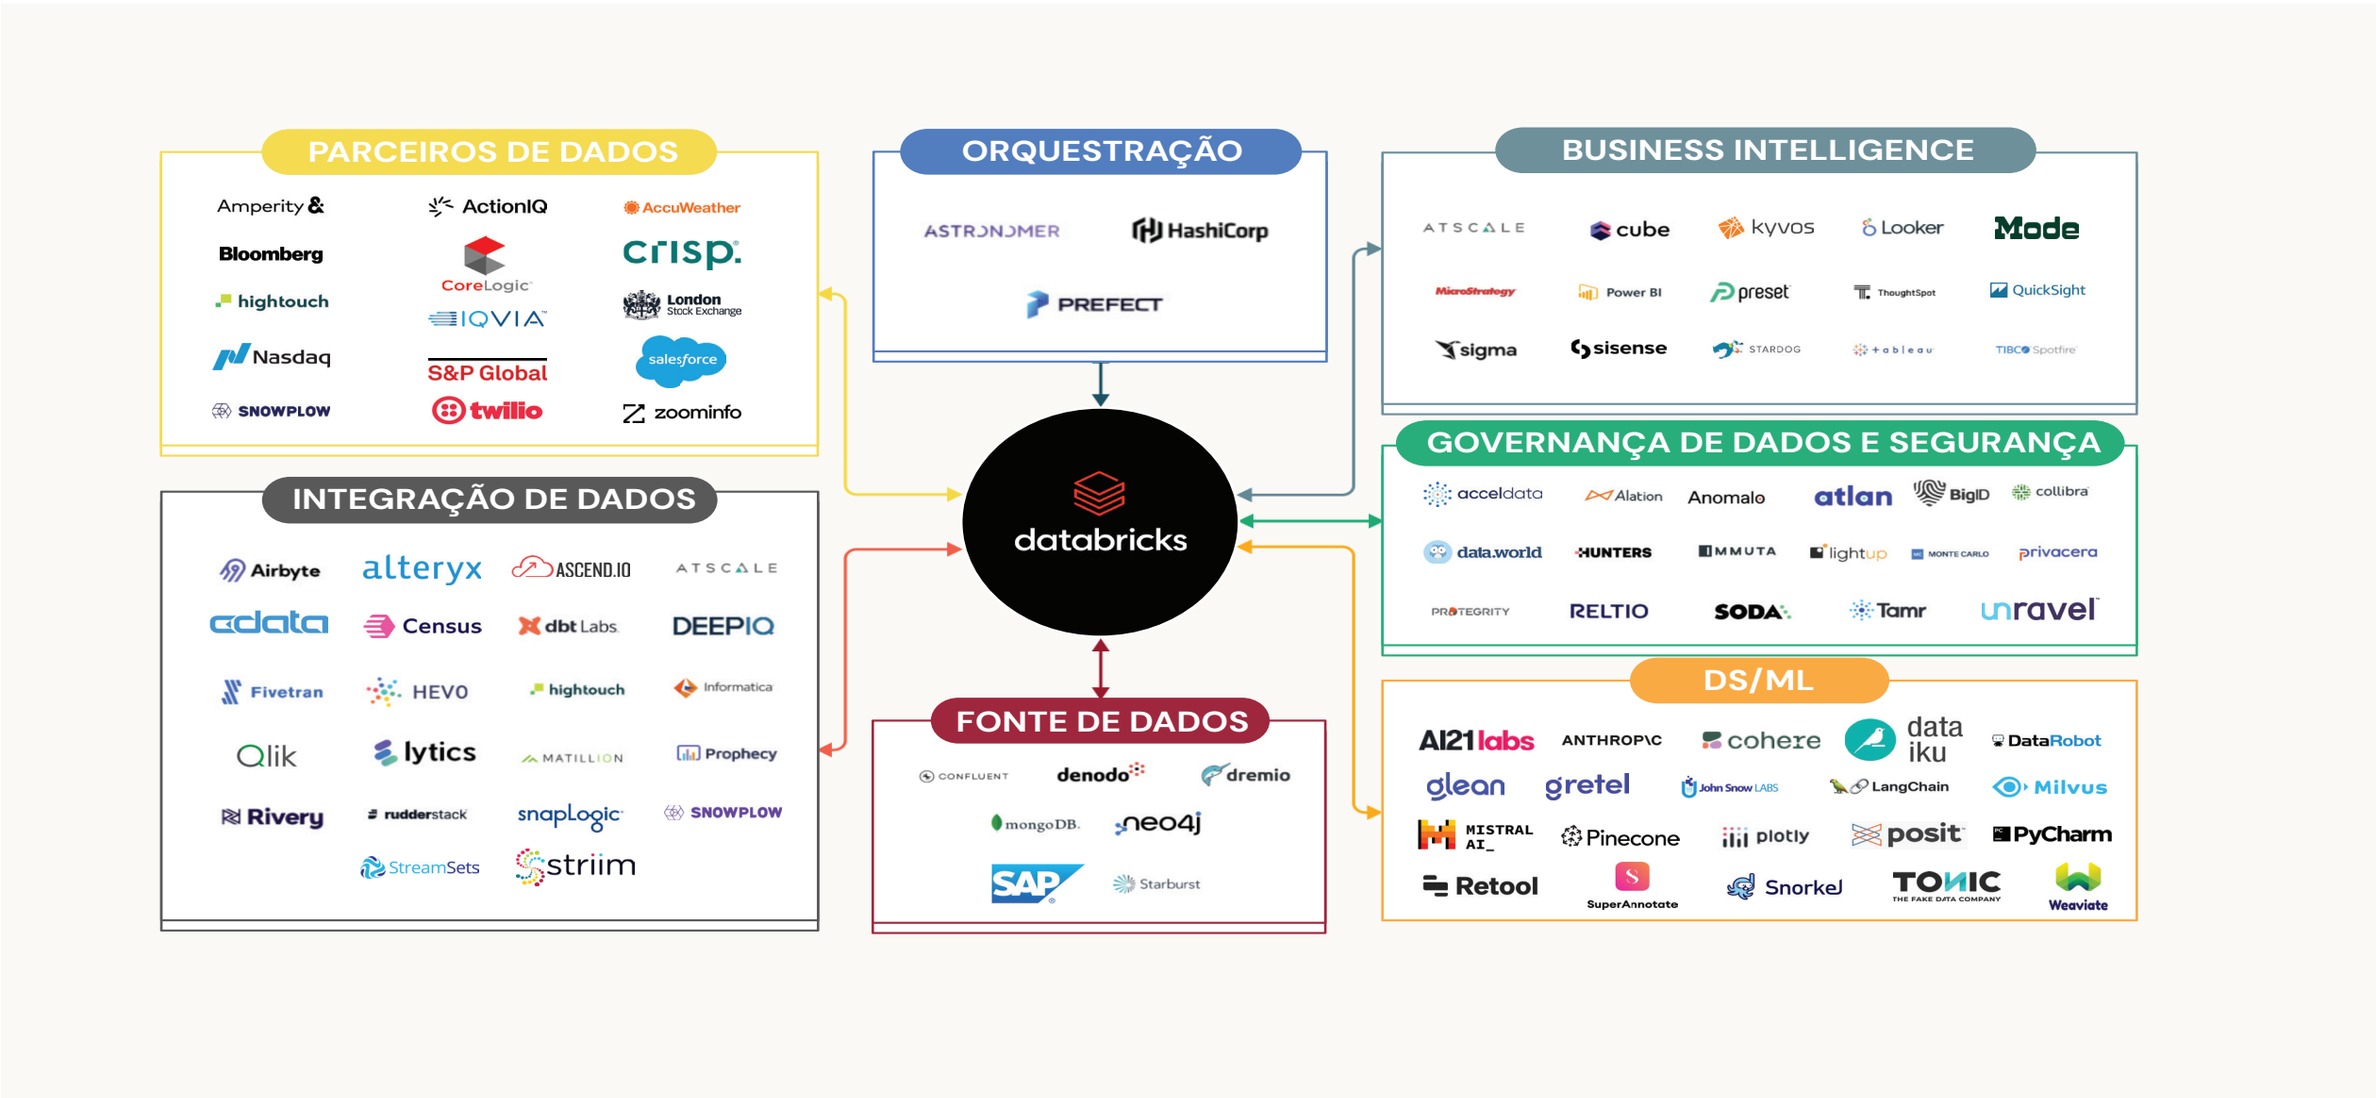

## Engenharia de dados unificada com o Databricks Lakeflow

O Lakeflow simplifica e unifica a experiência de engenharia de dados com uma plataforma ETL integrada e moderna construída sobre a Data Intelligence Platform. Sua interface intuitiva e centralizada para ingestão, transformação e orquestração de dados reduz a dispersão de ferramentas, acelera o tempo de produção e o valor, e libera a engenharia de dados para mais usuários em toda a organização. O Lakeflow permite que equipes de engenharia de dados avancem mais rápido e de forma mais confiável, sem comprometer a governança, a escalabilidade ou o desempenho.

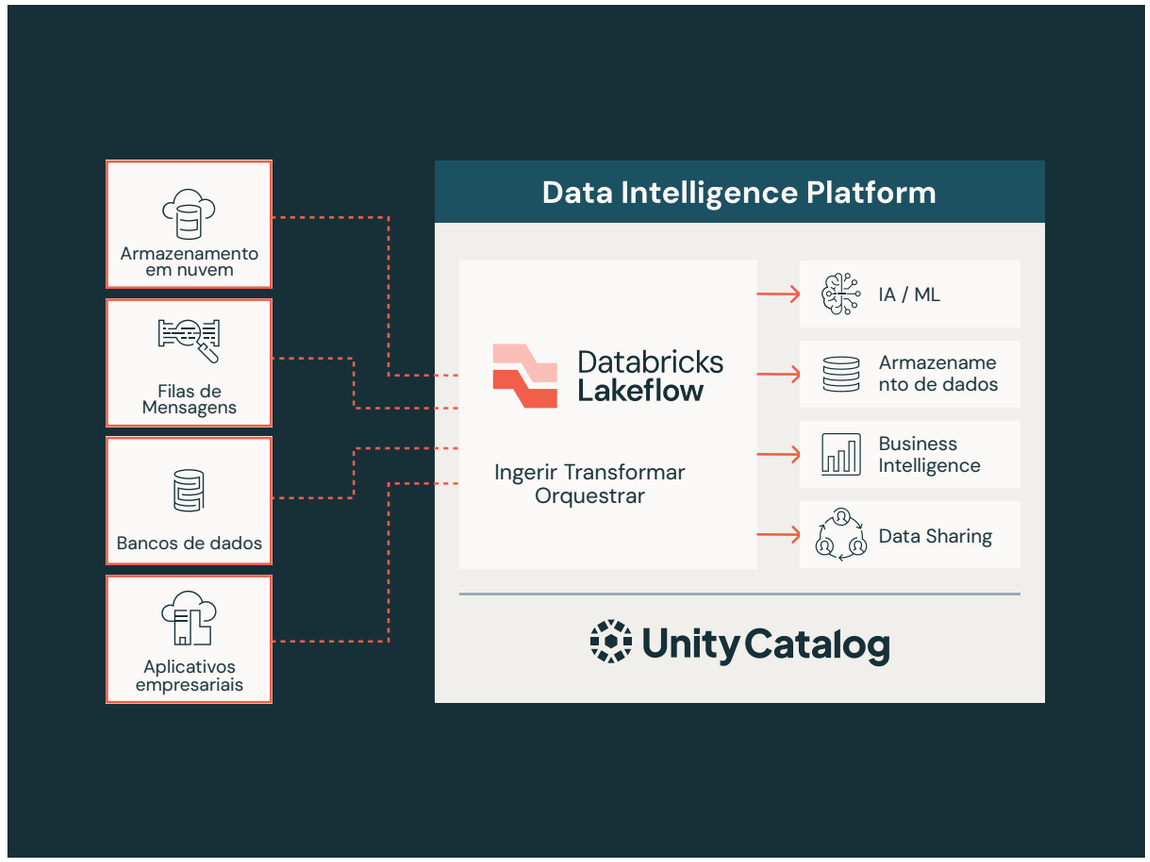


**Lakeflow** é composto por três componentes integrados:

- **Lakeflow Connect** para ingestão
- **Lakeflow Spark Declarative Pipelines** para transformação
- **Lakeflow Jobs** para orquestração

Além disso, o **Lakeflow Designer** é uma experiência sem código destinada a ajudar qualquer profissional a criar pipelines de dados com base no Lakeflow.

## INGESTÃO DE DADOS COM LAKEFLOW CONNECT

A Databricks permite que as organizações ingiram dados de diversos sistemas de forma eficiente em uma arquitetura de lakehouse única, aberta e unificada. O Lakeflow Connect oferece conectores simples para ingestão de dados de aplicativos, bancos de dados, armazenamento em nuvem, barramentos de mensagens e mais, diretamente no seu lakehouse. Esses conectores integrados proporcionam ingestão incremental de ponta a ponta eficiente e em escala, configuração fácil com uma interface de usuário intuitiva ou API, e governança unificada por meio do Unity Catalog. Com o Lakeflow Connect, a Databricks continua inovando, expandindo a gama de fontes de dados suportadas por meio de conectores integrados e gerenciados, bem como de conectores com mais opções de personalização. O Zerobus Ingest permite enviar dados de eventos diretamente para o seu lakehouse sem a necessidade de um barramento de mensagens, simplificando assim a ingestão para IoT, clickstream, telemetria e outros casos de uso semelhantes. O Auto Loader é um conector totalmente personalizável que fornece uma fonte de Structured Streaming para processar dados de forma incremental e eficiente à medida que chegam ao armazenamento de objetos em nuvem, sendo recomendado para uso com Pipelines Declarativos.

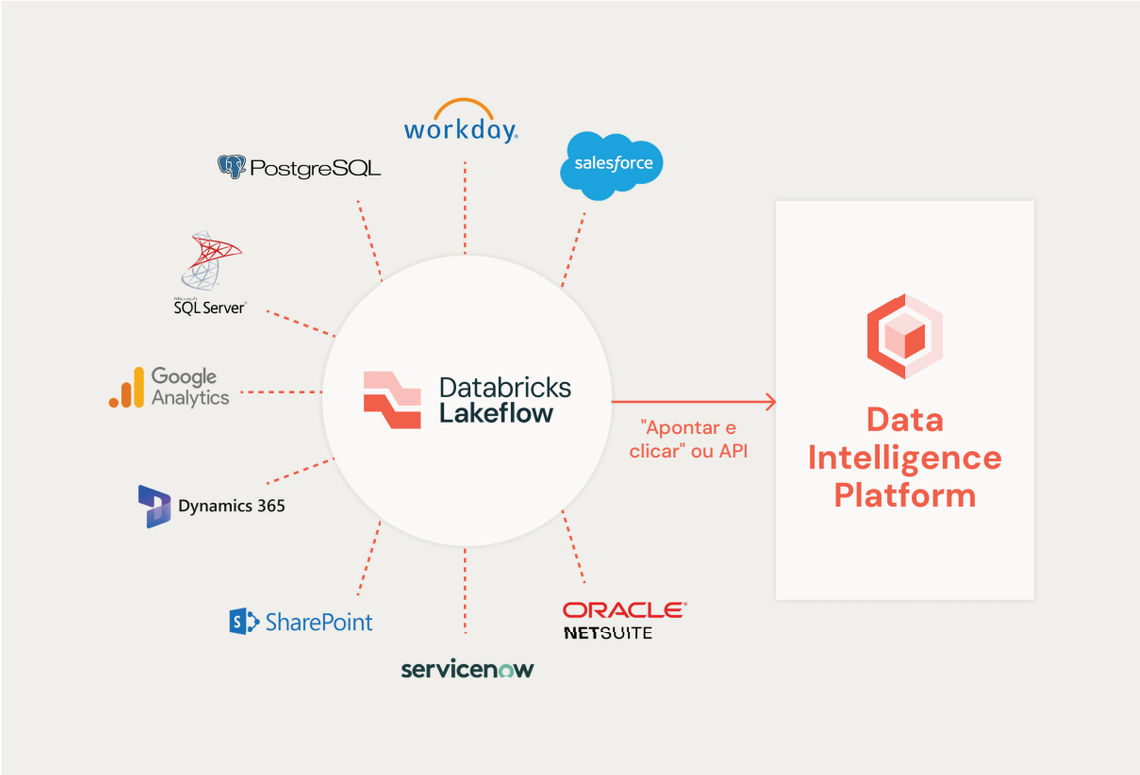


Conectores integrados de dados para aplicativos empresariais, fontes de arquivos e bancos de dados

## TRANSFORMAÇÃO DE DADOS PARA SPARK DECLARATIVE PIPELINES

O Spark Declarative Pipelines é uma estrutura ETL declarativa (construída no Apache Spark™ Declarative Pipelines de código aberto) que ajuda as equipes de dados a simplificar e tornar o ETL econômico em streaming e batch. Basta definir as transformações que você deseja realizar em seus dados e permitir que o Spark Declarative Pipelines lide automaticamente com a orquestração de tarefas, o gerenciamento de compute, o monitoramento, a qualidade de dados e o tratamento de erros. Os engenheiros podem tratar seus dados como código e aplicar as melhores práticas modernas de engenharia de software, como testes, tratamento de erros, monitoramento e documentação para implantar pipelines confiáveis em escala. O Declarative Pipelines oferece suporte total a Python e SQL e é adaptado para funcionar com cargas de trabalho em streaming e em batch.

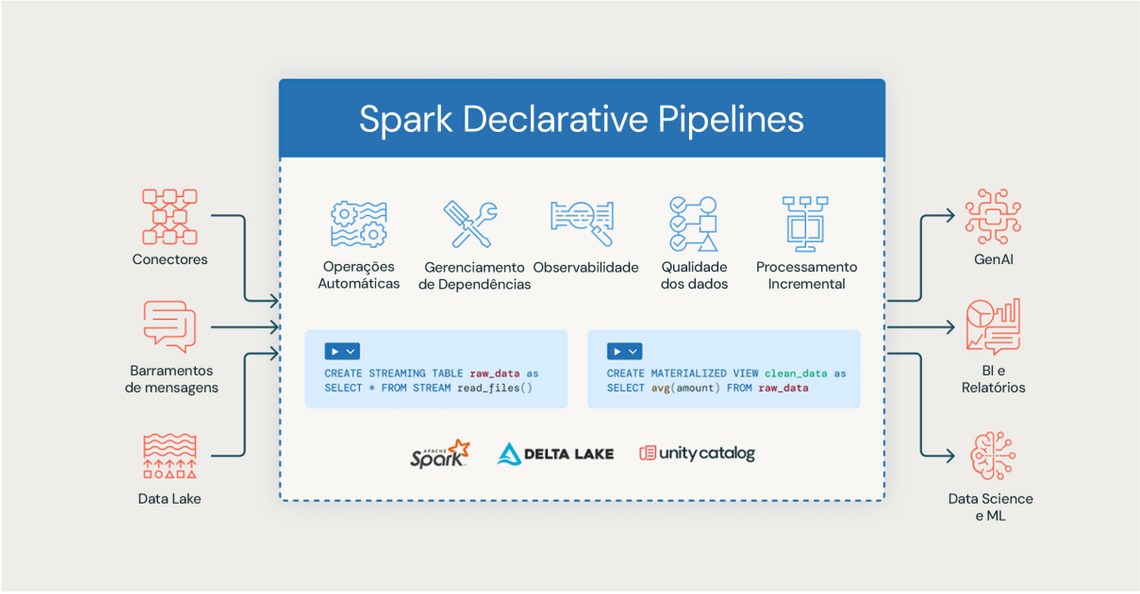


Pipelines de dados confiáveis simplificados com Spark Declarative Pipelines

## ORQUESTRAÇÃO UNIFICADA DE DADOS COM LAKEFLOW JOBS

O Lakeflow Jobs oferece uma solução de orquestração simples e confiável para dados, analytics e IA na Data Intelligence Platform. O Lakeflow Jobs permite que você defina fluxos de trabalho de várias etapas para implementar pipelines de ETL, workflows de treinamento de ML e muito mais. Ele oferece recursos aprimorados de fluxo de controle e suporta diferentes tipos de tarefas e opções de trigger de workflows. Como o orquestrador nativo da plataforma, o Lakeflow Jobs também fornece observabilidade avançada para monitorar e visualizar a execução do workflow, juntamente com recursos de alerta e solução de problemas para quando surgirem dificuldades. O Lakeflow Jobs oferece opções de compute serverless para que você aproveite o dimensionamento inteligente e a execução eficiente de tarefas.

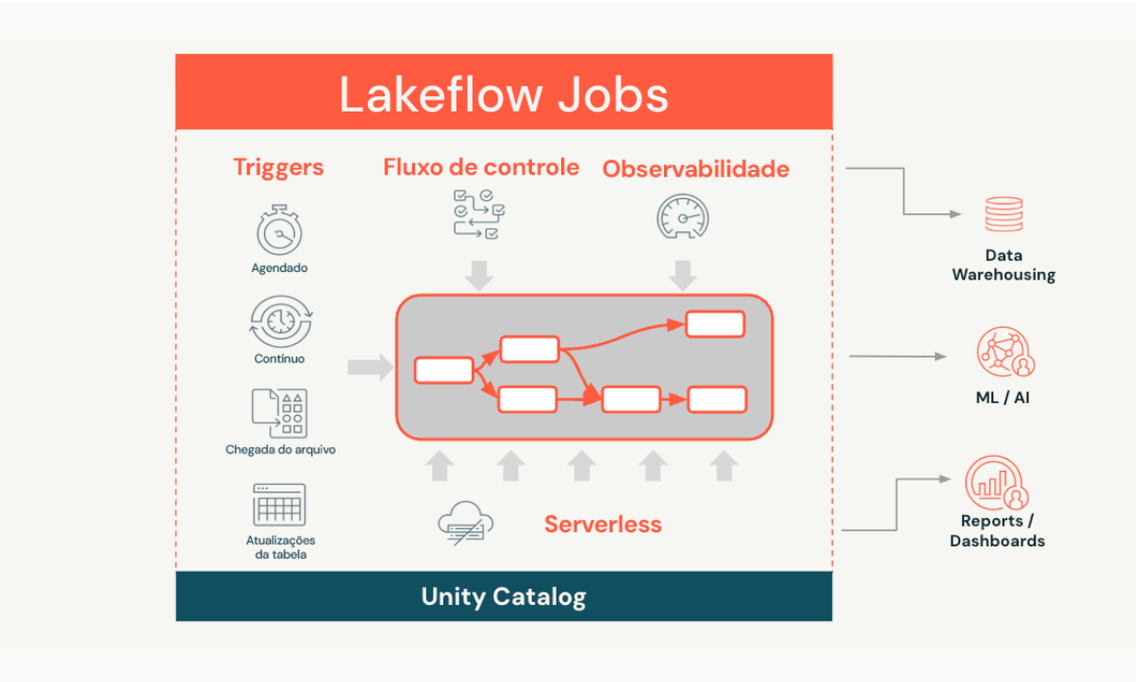


## PIPELINES DE DADOS DE NÍVEL DE PRODUÇÃO, SEM NECESSIDADE DE CÓDIGO, COM O LAKEFLOW DESIGNER

Projetos de analytics exigem colaboração entre engenheiros de dados e analistas de negócios, que geralmente trabalham em plataformas separadas. Embora as ferramentas no-code possam ajudar a preencher essa lacuna, os desafios permanecem: workflows isolados, complicações na produção e produtividade limitada da IA. O Lakeflow Designer resolve isso com uma ferramenta no-code e assistida por IA — nativa da Databricks Data Intelligence Platform — que capacita analistas de negócios e outros a criar pipelines de dados prontos para produção com linguagem natural. Alimentado por inteligência de dados, o Lakeflow Designer potencializa workflows compartilhados e colaborativos, com um caminho integrado para a produção, construído sobre uma IA que compreende o seu negócio.

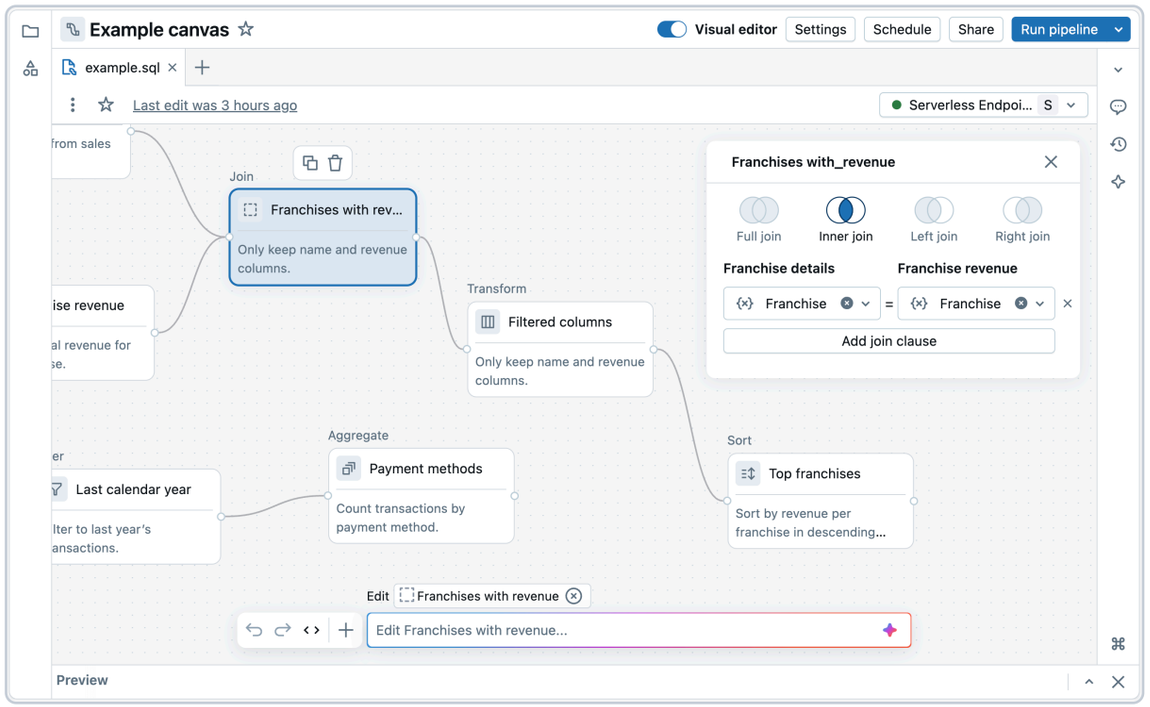

## Por que engenheiros de dados escolhem o Databricks Lakeflow e a Data Intelligence Platform

Então, como a Data Intelligence Platform e o Lakeflow contribuem para cada um dos desafios de engenharia de dados discutidos anteriormente?

- **Experiência unificada de engenharia de dados:** o Lakeflow reúne todos os principais aspectos da engenharia de dados, desde a ingestão (Lakeflow Connect) até a transformação (Spark Declarative Pipelines) e a orquestração (Lakeflow Jobs), em uma única solução criada com base na Data Intelligence Platform. Por meio de uma plataforma de dados centralizada e simplificada, é possível eliminar silos entre as equipes, minimizar a dispersão de ferramentas e melhorar a eficiência operacional.
- **Ingestão eficiente, ampla gama de conectores de dados:** o Lakeflow permite que você ingira dados de forma eficiente, trazendo apenas novos dados ou atualizações de tabelas. Com um conjunto crescente de conectores nativos para fontes de dados populares, bem como uma ampla rede de parceiros de ingestão de dados, você pode mover facilmente dados de sistemas isolados para sua plataforma de dados. Ingerir e armazenar seus dados no Delta Lake, enquanto aproveita a confiabilidade e a escalabilidade da Data Intelligence Platform, é o primeiro passo para extrair valor de seus dados e acelerar a inovação.
- **Processamento de stream de dados em tempo real:** o Lakeflow simplifica o desenvolvimento e as operações ao automatizar os aspectos de produção associados à construção e manutenção de workloads de dados em tempo real. O Spark Declarative Pipelines fornece uma maneira declarativa de definir pipelines de ETL de streaming, e o Spark Structured Streaming ajuda a construir aplicações em tempo real para tomada de decisões imediatas.
- **Pipelines de dados confiáveis em escala:** o Lakeflow utiliza dimensionamento automático inteligente e gerenciamento de recursos auto-otimizado para lidar com workloads de alta escala. Com a arquitetura lakehouse, a alta escalabilidade dos data lakes é combinada com a alta confiabilidade dos data warehouses, graças ao Delta Lake — o formato de armazenamento que está na base do lakehouse.
- **Qualidade dos dados:** alta confiabilidade — desde a camada de armazenamento com o Lakehouse Storage, combinada com recursos específicos de qualidade de dados oferecidos pelo Spark Declarative Pipelines — garante dados de alta qualidade. Esses recursos incluem a definição de "expectativas" para lidar com dados corrompidos ou ausentes, bem como tentativas automáticas de reprocessamento. Além disso, tanto o Lakeflow Jobs quanto o Spark Declarative Pipelines oferecem observabilidade completa aos engenheiros de dados, tornando a identificação e a resolução de problemas mais rápidas e simples.
- **Governança unificada com compartilhamento seguro de dados**: o Unity Catalog fornece um modelo de governança único para toda a plataforma, garantindo que cada conjunto de dados e pipeline seja governado de forma consistente. Os conjuntos de dados são descobríveis e podem ser compartilhados com segurança com equipes internas ou externas por meio do Delta Sharing. Além disso, como o Unity Catalog é uma solução de governança multiplataforma, ele oferece informações valiosas de linhagem, facilitando a compreensão completa de como cada conjunto de dados e tabela são utilizados downstream e de onde se originam upstream.

## Conclusão

À medida que as organizações buscam inovar aproveitando seus dados, a engenharia de dados é um ponto focal para o sucesso, fornecendo pipelines confiáveis e em tempo real que tornam possível a IA. Com o Databricks Lakeflow, construído em uma arquitetura lakehouse e impulsionado por inteligência de dados, os engenheiros de dados estão preparados para enfrentar os desafios críticos no cenário de dados moderno. Ao apoiar-se nas capacidades avançadas do Lakeflow e de toda a Data Intelligence Platform, os engenheiros de dados não precisam dedicar tanto tempo gerenciando pipelines complexos ou lidando com problemas de confiabilidade, escalabilidade e qualidade de dados. Em vez disso, eles podem se concentrar na inovação e em gerar mais valor para a organização.

Na próxima seção, descrevemos as práticas recomendadas para a engenharia de dados e apresentamos casos de uso completos extraídos de exemplos do mundo real. Da ingestão e do processamento em tempo real à orquestração e federação de dados, você aprenderá como aplicar padrões comprovados e fazer o melhor uso dos diferentes recursos do Lakeflow e da Data Intelligence Platform.

**Conheça as melhores práticas de engenharia de dados e histórias de clientes no Big Book of Data Engineering (somente em inglês).**

# 02

# Orientações e práticas recomendadas

# Migrando workloads ETL do Apache Spark™ para o Databricks

Por Dinesh Kumar

## Introdução

Migrar workloads ETL do Spark para a Databricks desbloqueia desempenho mais rápido, reduz custos e melhora a escalabilidade. Com suporte integrado para **Delta Lake**, gerenciamento automatizado de compute e um mecanismo **Spark** otimizado, a Databricks simplifica e moderniza seus pipelines de dados.

Neste capítulo, abordarei as melhores práticas para uma migração suave e eficiente, desde a avaliação do workload até o ajuste de desempenho. Seja levantando e deslocando, refatorando ou rearquitetando seus pipelines, essas etapas garantirão que você desbloqueie todo o potencial da Databricks.

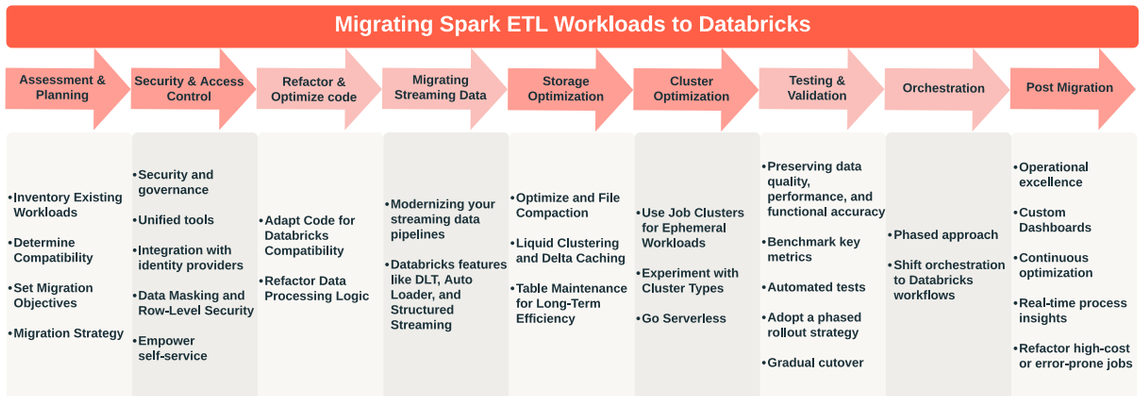


## Avaliação e planejamento para migração para Databricks

Uma migração bem-sucedida para a Databricks começa com uma abordagem estruturada, incluindo um inventário abrangente dos workloads existentes, avaliação de compatibilidade e definição de objetivos claros de migração.

1. Faça um **inventário dos workloads existentes:** classifique seus workloads como batch ou streaming e documente os principais ativos para migração, incluindo jobs, workflows, parâmetros, utilização de recursos, frequência de execução e consumidores de dados. Um inventário completo fornecerá uma visão geral clara dos componentes prontos para migração.
2. **Determine a compatibilidade:** identifique quaisquer funcionalidades proprietárias ou específicas do ambiente que possam não ser diretamente compatíveis com a Databricks. Você também deve identificar e avaliar os provedores de nuvem e as dependências de serviços externos para garantir uma integração tranquila durante a migração.
3. **Defina objetivos de migração:** defina metas claras e critérios de sucesso para a migração, incluindo custo de posse, governança, melhorias de desempenho, escalabilidade e simplicidade da arquitetura
4. **Escolha a estratégia de migração correta:** a chave para uma migração bem-sucedida da Databricks é escolher a estratégia certa: lift-and-shift, refatorar ou rearquitetar. Cada opção tem suas vantagens e desvantagens em relação ao esforço, à flexibilidade e à escalabilidade a longo prazo. O lift-and-shift é a estratégia mais rápida, envolvendo mudanças mínimas nos workloads. Ele permite que você aproveite imediatamente os benefícios de desempenho e custo da Databricks, proporcionando um rápido retorno sobre o investimento (ROI). Embora possa não ser uma arquitetura totalmente otimizada, acelera a geração de valor e prepara o terreno para melhorias futuras.

Para mais detalhes, consulte nossa documentação aqui.

## Segurança e controle de acesso

À medida que seus dados são escalados na Databricks, segurança e governança robustas se tornam essenciais. As ferramentas unificadas da Databricks ajudam a centralizar as permissões de dados, possibilitando inovações descentralizadas e seguras entre as equipes.

O Unity Catalog é a base para unificar a governança, fornecendo permissões refinadas em catálogos, esquemas, tabelas, visualizações e colunas. Ele também captura a linhagem de dados em runtime, facilita a descoberta de dados por meio do explorador do catálogo e permite o monitoramento por meio de logs de auditoria. O Unity Catalog também ajuda a proteger dados sensíveis com mascaramento integrado e segurança em nível de linha.

A federação de identidades simplifica o gerenciamento centralizado de usuários e grupos ao integrar-se a provedores de identidade como Azure AD ou Okta. O provisionamento SCIM automatiza a sincronização de usuários e grupos, oferecendo suporte ao gerenciamento contínuo de acesso e ao Single Sign-On (SSO) para uma experiência de usuário aprimorada.

Adotar a arquitetura Data Mesh para governança federada e atribuir a propriedade dos dados a equipes específicas de cada domínio acelera a tomada de decisões, capacita as equipes a gerenciar seus dados e aumenta a agilidade e a escalabilidade.

Os templates Terraform também ajudarão a automatizar a implantação de recursos e manter a escalabilidade em toda a plataforma, garantindo consistência e segurança da infraestrutura.

## Refatore e otimize o código

Otimizar e refatorar seu código é crucial para melhorar a compatibilidade e o desempenho na Databricks ao mesmo tempo em que estabelece uma base sólida para o sucesso a longo prazo.

### ADAPTE O CÓDIGO PARA COMPATIBILIDADE COM DATABRICKS

Embora o Lift-and-Shift possa acelerar a implantação, o código legado pode afetar o desempenho e a estabilidade. Gostaria que você aproveitasse esta oportunidade para auditar e simplificar seus pipelines, identificando componentes que podem não se integrar perfeitamente à Databricks. Os desafios comuns incluem JARs personalizados, UDFs do Hive e configurações específicas da infraestrutura que podem precisar de refatoração para se alinharem ao ambiente nativo em nuvem da Databricks. Abordar proativamente essas questões ajuda a reduzir o débito técnico e garante migrações mais suaves e estáveis.

### REFATORE A LÓGICA DE PROCESSAMENTO DE DADOS

A refatoração da lógica de processamento de dados legados moderniza seus pipelines e simplifica a migração. As ferramentas Remorph Transpile e BladeBridge podem automatizar a conversão de código SQL, reduzindo o esforço manual. Aproveitar o Delta Lake aumenta a confiabilidade e o desempenho com recursos como transações ACID e imposição de esquema, garantindo compatibilidade e fornecendo uma base escalável para o crescimento futuro.

# Migre dados de streaming para a Databricks: simplifique e otimize seus pipelines

Migrar pipelines de dados em streaming para a Databricks pode desbloquear insights mais rápidos, melhorar o desempenho e reduzir custos operacionais. Esteja você se afastando de processadores de stream legados ou consolidando múltiplas ferramentas, a Databricks oferece um caminho de migração contínuo, oferecendo recursos essenciais projetados para desempenho mais ágil, escalabilidade e facilidade de gerenciamento.

## SPARK DECLARATIVES PIPELINES (SDP): SIMPLIFICANDO PIPELINES DE DADOS EM STREAMING

O SDP simplifica a construção e o gerenciamento de pipelines de streaming, permitindo o uso de SQL ou Python em um formato declarativo. Ele gerencia automaticamente a orquestração, as novas tentativas e as dependências, para que você possa se concentrar na lógica do pipeline em vez dos desafios operacionais.

O SDP oferece suporte a dados em batch e streaming, simplificando a migração de workloads de streaming e melhorando a capacidade de manutenção do pipeline ao reduzir a necessidade de múltiplas ferramentas ou soluções personalizadas.

## PRINCIPAIS CARACTERÍSTICAS DO SPARK DECLARATIVE PIPELINES

- **Pipelines de streaming declarativos:** simplifica a criação de pipelines ao eliminar detalhes de baixo nível, como agendamento, novas tentativas e gerenciamento de estados, permitindo que os desenvolvedores foquem na lógica de negócios
- **Modos batch e contínuos:** oferece suporte a batch e streaming em tempo real, oferecendo flexibilidade para diversas necessidades de processamento de dados
- **Verificações de qualidade dos dados:** verificações integradas de qualidade dos dados para garantir o processamento preciso dos dados
- **Evolução do esquema:** a adaptação às mudanças no modelo de dados reduz o esforço manual e garante a robustez do pipeline
- **Publicação em múltiplos catálogos:** permite a publicação de dados em vários catálogos para acesso e gerenciamento flexíveis

## AUTO LOADER: INGESTÃO ESCALÁVEL COM SOBRECARGA MÍNIMA

O Auto Loader simplifica a ingestão incremental de arquivos do armazenamento em nuvem (por exemplo, S3, ADLS). Ele infere esquemas automaticamente, adapta-se a alterações de esquema em tempo real e lida com workloads de alto volume e baixa latência. O Auto Loader é ideal para migrações de streaming, garantindo um gerenciamento eficiente e contínuo do pipeline de dados.

## STRUCTURED STREAMING: ANÁLISE EM TEMPO REAL EM ESCALA

O Structured Streaming, baseado no Apache Spark, oferece flexibilidade e resiliência para sua arquitetura de streaming. Combinado com o **Delta Lake**, proporciona processamento de baixa latência, semântica exactly-once e conformidade com ACID, permitindo pipelines de dados escaláveis e confiáveis em tempo real.

## LAKEFLOW CONNECT: INTEGRAÇÃO SIMPLIFICADA COM FONTES EXTERNAS

O Lakeflow Connect oferece conectores totalmente gerenciados para facilitar a ingestão de dados de aplicativos SaaS e bancos de dados em seu lakehouse. Com a tecnologia do Unity Catalog e compute serverless, ele garante uma ingestão incremental de dados rápida, escalável e econômica, mantendo seus dados atualizados e prontos para uso posterior.

## Otimizando armazenamento e acesso de dados na Databricks

À medida que os volumes de dados aumentam, otimizar a forma como os dados são armazenados e acessados se torna essencial para manter o desempenho, reduzir custos e garantir a confiabilidade. A Databricks oferece vários recursos avançados para otimizar o Delta Lake e aprimorar o desempenho em grande escala.

### PRINCIPAIS OTIMIZAÇÕES:

- **Otimização e compactação de arquivos:** resolva problemas com arquivos pequenos usando compactação automática e gravações otimizadas, mas ainda conte com OPTIMIZE para ajustes manuais precisos. Além disso, o **Liquid Clustering** e o **Z-Ordering** podem ser usados para ajustar a organização dos dados com base em campos previstos, a fim de melhorar ainda mais o desempenho.
- **Cache em disco e mecanismo de execução Photon:** o Cache Delta armazena dados acessados com frequência na memória ou em SSDs para reduzir a latência de query, e o mecanismo de execução Photon executa cargas de trabalho e queries com mais eficiência
- **Otimização preditiva:** elimina a necessidade de gerenciar as operações de manutenção para tabelas gerenciadas manualmente pelo Unity Catalog na Databricks

Caso necessite de mais informações, consulte as melhores práticas para otimização de desempenho, ajuste de tamanho do arquivo e documentação sobredelta vacuum.

## Gerenciamento e otimização de clusters na Databricks

Otimizar configurações de cluster é essencial para equilibrar desempenho e custo na Databricks. Uma abordagem com reconhecimento do workload é fundamental e você deve experimentar diferentes tipos e configurações de cluster que melhor atendam aos requisitos do seu pipeline.

### MELHORES PRÁTICAS:

- **Job clusters:** use job clusters para workloads efêmeras para minimizar os custos de inatividade
- **Tipos de cluster:** selecione VMs otimizadas para memória para tarefas pesadas em cache e VMs otimizadas para compute para transformações de alto throughput
- **Dimensionamento automático:** ative o dimensionamento automático para ajustar os recursos com base na demanda de workload automaticamente
- **Serverless:** opte por serverless para eliminar a sobrecarga de gerenciamento de clusters para queries ad hoc e painéis de BI

Caso necessite de mais informações, consulte configuração de cluster, otimização de custo para o data lakehouse, Guia abrangente para otimizar cargas de trabalho Databricks, Spark, e Delta Lake e se conectar ao compute serverless.

## Teste e validação para migração de workload de ETL

Migrar workloads ETL não é apenas mover código — é preservar a qualidade dos dados, o desempenho e a precisão funcional. Automatize testes para validar a precisão dos dados e dependências do pipeline, além de usar benchmarks para métricas-chave a fim de acompanhar melhorias de desempenho.

A abordagem recomendada é automatizar testes com ferramentas como Remorph Reconcile, DataCompy ou SQLglot. Essas ferramentas ajudam a reduzir o esforço manual, aumentando a confiança no sucesso da sua migração.

Também é essencial adotar uma estratégia de implantação em fases, executando os sistemas novos e legados lado a lado para validação e monitoramento antes de migrar totalmente para a Databricks. Essa abordagem garante uma migração de baixo risco com interrupção mínima.

## Gerenciamento e orquestração de workflows no Databricks

A migração da orquestração para Lakeflow Jobs pode simplificar o gerenciamento de ETL, aprimorar o tratamento de dependências e permitir o monitoramento centralizado. A Databricks oferece suporte nativo **a Apache Airflow** por meio do DatabricksRunNowOperator, permitindo que você migre a orquestração sem interromper seus DAGs existentes. Com o tempo, considere migrar os workflows para a interface visual nativa da Databricks e a configuração baseada em YAML para obter mais flexibilidade e facilidade de uso.

## Monitoramento e otimização após a migração

Após a migração, manter um ambiente Databricks eficiente é crucial. Ferramentas integradas como **Spark UI**, **Databricks Metrics UI**, **System Tables** e **Cluster Event Logs** podem ajudar a obter insights sobre execução, uso de recursos e comportamento do cluster.

À medida que os workloads se estabilizam, ajuste o desempenho analisando dados em tempo real. Ajuste os recursos dimensionando corretamente os clusters, refinando o escalonamento automático e otimizando as estratégias de particionamento ou armazenamento em cache para melhorar o desempenho das queries e reduzir a E/S.

Referências adicionais estão disponíveis em criar um painel, painel de uso e visão geral das tabelas do sistema.

## Conclusão

A migração para a Databricks requer planejamento cuidadoso, execução e otimização contínua. Ao seguir uma abordagem estruturada, avaliando workloads, otimizando código e aproveitando os recursos poderosos da Databricks, você pode garantir uma migração fluida que melhora o desempenho, a escalabilidade e a eficiência de custos sem interromper o negócio em andamento. Com a Databricks, sua organização pode escalar os pipelines de processamento de dados, reduzindo simultaneamente os custos operacionais, preparando você para o sucesso a curto prazo e o crescimento a longo prazo.

**Conheça as melhores práticas de engenharia de dados e histórias de clientes no Big Book of Data Engineering (somente em inglês).**

# 03

# Estudos de caso

NAVY FEDERAL Credit Union

HISTÓRIA DE CLIENTE

# NFCU: Usando dados em tempo real para abrir caminho na personalização dos membros

SETOR Serviços financeiros

NUVEM Azure

**Bilhões**
de eventos de aplicativos por mês processados pelo Spark Declaratives Pipelines

**9 bilhões**
eventos disponibilizados em streaming continuamente por 9 meses, 24 horas por dia, 7 dias por semana, com 100% de zero manutenção

**6 semanas**
tempo de lançamento de uma nova aplicação omnicanal em tempo real

databricks



> A simplicidade do modelo de programação Spark Declarative Pipelines, combinada com suas capacidades de serviço, resultou em um tempo de resposta incrivelmente rápido. Isso nos permitiu levar um novo tipo de workload para produção em tempo recorde e com alta qualidade.
>
> **— Jian (Miracle) Zhou, Gerente Sênior de Engenharia, Navy Federal Credit Union**

A Navy Federal Credit Union foi fundada durante a Grande Depressão por sete funcionários da Marinha dos EUA que queriam ajudar a si mesmos e a seus colegas de trabalho no alcance de suas metas financeiras. Hoje, a Navy Federal Credit Union é a maior cooperativa de crédito do mundo, atendendo 13 milhões de membros-proprietários. A prioridade da Navy Federal é oferecer uma experiência personalizada e omnicanal aos seus membros. Mas, para entender melhor seus membros, eles precisavam absorver e analisar dados de telemetria online em tempo real. Para isso, a Navy Federal recorreu ao Spark Declarative Pipelines, Databricks SQL e Microsoft Power BI.

## Dados quase em tempo real introduzem novos insights

Em junho de 2023, a Navy Federal estava prestes a iniciar o processo de migração de milhões de usuários para a versão mais recente de sua plataforma de banco online. A empresa planejava concluir essa migração de forma controlada com pequenos grupos de usuários, expandindo-se gradualmente para todos os seus membros ao longo de vários meses.

Para tomar decisões informadas, a Navy Federal precisava monitorar de perto a forma como seus membros interagiam com seus produtos. Para isso, os engenheiros da Navy Federal criaram pipelines de dados para seu data lake, e os analistas de dados desenvolveram painéis e relatórios para visualizar os KPIs. Os pipelines eram executados diariamente, de modo que as informações do dia anterior estariam disponíveis para a liderança no início de um novo dia. “O pipeline funcionou perfeitamente, mas no mundo de hoje, 24 horas é um tempo de resposta muito longo”, disse Jian (Miracle) Zhou, gerente sênior de engenharia da Navy Federal Credit Union. “À medida que nos aproximávamos da primeira onda de migração de usuários, decidimos aprimorar nossa solução de dados para introduzir novas informações em tempo quase real.”

Para isso, a organização precisava criar um painel quase em tempo real com dois KPIs: o número de membros exclusivos que conseguiam fazer login no novo canal e o número de sessões exclusivas que o canal atendia. Além disso, eles precisavam filtrar os KPIs por tempo e por atributo de membro, que servia como indicador da onda de migração a que pertenciam. A expectativa era que o painel fosse atualizado continuamente ao longo do dia com uma latência de no máximo 10 minutos.

Zhou enfrentou dois desafios principais: tempo e escala. A organização teve cerca de seis semanas para construir uma solução do zero e colocá-la em produção. "Na verdade, essa foi a primeira vez que minha equipe tentou construir uma solução em tempo real no Azure Cloud, e tivemos que resolver tudo em seis semanas", disse ele. “E em termos de escala, estamos falando de bilhões de eventos de aplicativos gerados por milhões de usuários ativos mensais, então a solução teve que ser expandida à medida que a migração prosseguia.”

## O Databricks Spark Declarative Pipelines ajuda a criar pipeline de dados confiável e de alto desempenho

As soluções de entrega de dados da Navy Federal seguem um caminho direto. Um lado é para engenheiros e é totalmente focado na ingestão e curadoria de dados. Para cada fonte de dados, eles criam um pipeline para ingerir dados em seu data lake, transformá-los e prepará-los para serem consumidos pelos clientes. Essa parte da equação é muito dinâmica devido à diversidade de suas fontes de dados. O outro lado é para analistas de dados e é totalmente focado em servir e visualizar dados. A Navy Federal usa Azure Data Lake Storage como camada de armazenamento, Databricks SQL como mecanismo de query analítico e Power BI para visualização de dados. Juntos, eles formam uma base simples, porém eficaz, para a análise de dados.

A fonte de dados com a qual a Navy Federal precisava trabalhar era a telemetria de eventos gerada em seu aplicativo de banco online.

A Navy Federal Credit Union enfrentou desafios ao usar o Azure Application Insights para painéis devido à falta de acesso aos dados dos atributos dos membros. Para resolver isso, eles fizeram streaming de telemetria do Application Insights para seu data lake usando o Azure Event Hubs, que suportava o protocolo Kafka para consumo de dados de baixa latência e alta confiabilidade sem necessidade de programação.

Para processar os dados em stream, a Navy Federal utilizou Databricks Spark Declarative Pipelines. Zhou e sua equipe usaram o Spark Declarative Pipelines para criar um pipeline de dados simples, escrevendo três funções de query e duas funções de captura de dados de alteração. A primeira função que eles escreveram conecta-se aos hubs de eventos, aplica alguma transformação e retorna um data frame. A segunda função de query pega documentos JSON complexos e os achata em registros individuais de eventos de aplicação. Eles então usaram a função APPLY CHANGES do Spark Declarative Pipelines para remover duplicatas. Na terceira função de query, eles filtraram os dados para apenas os eventos de login e depois selecionaram apenas as colunas relevantes para o login.

Por último, eles usaram a função APLICAR ALTERAÇÕES novamente para garantir que não haja duplicatas na tabela de eventos de login. Por fim, eles ajudaram o Spark Declarative Pipelines a entender quais dados devem ser mantidos e quais podem permanecer na memória (mas não podem ser acessados pelo mundo externo) quando um pipeline é executado. A equipe então usou o recurso Expectativas para definir expectativas de qualidade dos dados e monitorar a saúde desses dados. "É só isso — três funções de query e duas chamadas CDC para completar as quatro etapas. Simples assim", disse Zhou. “Para mim, isso significa complexidade low-code e tempo curto de desenvolvimento.”

De forma crítica, o pipeline que Zhou e sua equipe criaram escala de forma agressiva, o que foi importante à medida que a migração omnicanal dos usuários avançava. "Começamos com uma onda muito pequena e fomos aumentando o tamanho da migração, onda após onda. Esperávamos que isso aumentasse a demanda por recursos de compute, mas não tínhamos certeza de quanto exatamente era necessário para cada onda. Então, quando implantamos esse pipeline de dados em produção, ativamos um recurso chamado dimensionamento automático", explicou Zhou. “O volume de processamento aumentou rapidamente, de apenas algumas centenas de usuários e alguns milhares de sessões todos os dias para milhões de usuários e bilhões de eventos de aplicação por mês. Este pipeline escalou automaticamente os recursos dependendo do volume de dados. Nossos engenheiros de suporte de produção nunca precisaram intervir. Eles praticamente se esqueceram disso. "O pipeline também era confiável e tolerante a falhas. Ele executou streaming contínuo 24 horas por dia, 7 dias por semana, durante nove meses e processou com sucesso cerca de nove bilhões de eventos de aplicativos com quase nenhuma manutenção. "Em alguns dias, houve incidentes que causaram interrupções temporárias", disse Zhou. "Esses contratempos foram o resultado natural de estarmos em um ambiente de nuvem. O melhor de tudo é que o pipeline mostrou grande resiliência. Sem exceção, ele se recuperou automaticamente desses erros transitórios."

O pipeline também apresentava bom desempenho. Mesmo com o volume de dados de eventos disparando, o pipeline conseguiu acompanhar. "A velocidade de processamento do streaming e o tempo de resposta da query foram satisfatórios. Um dos motivos é que o Spark Declarative Pipelines otimiza, compacta e limpa automaticamente as tabelas que gerencia", disse Zhou. “Isso elimina ou reduz efetivamente o problema de arquivos pequenos e remove arquivos desnecessários de nossa conta de armazenamento, o que leva a um melhor desempenho de query.”

O último trecho da jornada foi a entrega do painel. O Databricks SQL permitiu que eles selecionassem dados no Power BI com agilidade e em grande escala. “Nossos analistas conectam o Power BI aos dados em nosso data lake através do endpoint do Databricks SQL, constroem modelos semânticos do Power BI e criam insights para visualizações”, explicou Zhou. “Nosso painel executa queries diretamente na Databricks. Quando as visualizações são renderizadas, isso traz as atualizações mais recentes para os usuários em tempo real.”

## Os Spark Declarative Pipelines levam um novo tipo de workload para produção em tempo recorde

Utilizando o Spark Declarative Pipelines, a Navy Federal conseguiu concluir uma prova de conceito em uma semana; desenvolver, testar e definir um processo de CI/CD em três semanas; implantar o pipeline em produção pouco antes da data de start da primeira onda de migração; e lançar o painel de controle apenas alguns dias depois.

“A simplicidade do modelo de programação Spark Declarative Pipelines, combinada com seus recursos de serviço, resultou em um tempo de resposta incrivelmente rápido”, disse Zhou. "Isso realmente nos permitiu levar um tipo totalmente novo de workload para a produção em tempo recorde e com boa qualidade."

O lançamento do painel de monitoramento da atividade dos usuários em tempo real, combinado com visualizações históricas, revelou tendências de longo prazo, que receberam um feedback extremamente positivo da alta liderança e das partes interessadas da Navy Federal.

"O Spark Declarative Pipelines esconde a complexidade da engenharia de dados moderna sob seu modelo de programação simples, intuitivo e declarativo", disse Zhou. "Como gerente de engenharia, adoro o fato de que meus engenheiros podem focar no que mais importa para o negócio." O Spark Declarative Pipelines pode cuidar do que está abaixo da superfície e garantir não apenas que nosso pipeline seja construído e implantado a tempo, mas também tenha uma boa manutenção a longo prazo.

Depois que a primeira versão do novo pipeline entrou em produção, Zhou e sua equipe continuaram a inovar, usando o Spark Declarative Pipelines para desenvolver e implantar uma estrutura interna orientada por metadados.

Zhou disse que as três coisas que ele mais gosta nos Spark Declarative Pipelines são:

- O modelo de programação declarativa simples que acelerou a velocidade de lançamento no mercado
- Escalabilidade, otimização e confiabilidade integradas — o que simplificou as operações
- Acessibilidade por meio da API, que permitiu espaço para criatividade e escalabilidade na engenharia

HISTÓRIA
DE CLIENTE

# Cincinnati Reds: vencendo dentro e fora de campo com análises de ponta no beisebol

SETOR Mídia e entretenimento

NUVEM Azure

**3–5x**
Melhora na latência com Databricks Lakeflow Jobs serverless

**1.000s**
De horas de tempo de compute economizadas diariamente

**83%**
Redução no runtime do pipeline

Com o Databricks Lakeflow Jobs serverless, obtivemos uma melhoria de 3 a 5 vezes na latência. O que antes levava 10 minutos, agora leva apenas 2 a 3 minutos, reduzindo significativamente o tempo de processamento. Isso nos permitiu fornecer feedbacks mais rápidos para jogadores e treinadores, garantindo que eles recebam as informações necessárias em tempo quase real para tomar decisões práticas.

**— Bryce Dugar, Gerente de Engenharia de Dados, Cincinnati Reds**

No competitivo mundo da liga principal de beisebol, cada decisão e ação pode fazer a diferença entre vencer e perder. Entendendo como os dados em tempo real podem oferecer uma vantagem competitiva, os Cincinnati Reds procuraram modernizar sua infraestrutura antiga, que era complexa de manter em grande escala. Para acelerar seus workloads e alcançar maior eficiência operacional, eles priorizaram as capacidades serverless como parte de sua estratégia de transformação. Ao adotar a Databricks Data Intelligence Platform, eles transformaram completamente a forma como gerenciam e analisam grandes conjuntos de dados. Com o Lakeflow Jobs da Databricks, os processos são automatizados e os pipelines de dados entregam insights em tempo real que impulsionam decisões mais inteligentes e rápidas — dando aos jogadores e treinadores as ferramentas necessárias para vencer no mais alto nível.

## Sistemas legados falham em fornecer insights oportunos

O Cincinnati Reds, uma das franquias mais antigas da Major League Baseball, enfrentava desafios de infraestrutura legada e dados que impediam sua capacidade de tomar decisões mais inteligentes e rápidas sobre os ciclos de feedback no beisebol para vencer mais jogos. Na última década, o volume e a complexidade do streaming de dados aumentaram em até 100 vezes, impulsionados pelo aumento dos dispositivos e sensores da Internet das Coisas (IoT) que monitoram o desempenho dos jogadores, a atividade no estádio e o envolvimento dos torcedores. Esse crescimento criou desafios significativos no manuseio e processamento de dados em seus sistemas locais. Processar bilhões de linhas e queries frequentemente levava horas ou até dias, tornando aplicações em tempo real impraticáveis. A escalabilidade era limitada, forçando a solução manual de problemas que consumia tempo valioso.

A latência também se tornou um fator crítico, com os usuários esperando acesso imediato a insights e relatórios que antes só estavam disponíveis após longos atrasos. Os dados também precisavam ser acessíveis e utilizáveis para diferentes funções. De cientistas de dados que processam grandes quantidades de dados e treinam modelos para ajudar a equipe a fazer previsões até usuários menos técnicos da empresa que precisam apenas de pequenas informações para ajudar a impulsionar a tomada de decisões estratégicas. Além disso, desenvolvedores de aplicações precisam de acesso programático aos repositórios de dados.

"Grande parte do que fazíamos antes era apenas resolver problemas como linhas ausentes ou dados não processados. Passávamos horas somente corrigindo esses problemas, em vez de realmente gerar insights ou melhorar o desempenho. Nossa equipe não conseguia acompanhar o crescente volume e variedade de dados — e essa abordagem manual nos deixou em desvantagem, especialmente com a demanda por informações em tempo real em um esporte tão dinâmico quanto o beisebol", explicou Bryce Dugar, gerente de engenharia de dados do Cincinnati Reds.

O Cincinnati Reds percebeu que precisava de uma solução mais escalável e eficiente, já que suas necessidades de dados cresciam rapidamente. Reconhecendo as limitações de seus sistemas tradicionais, os Reds adotaram a Databricks Data Intelligence Platform para automatizar workflows e permitir o acesso aos dados em tempo real. Especificamente, com o Databricks Lakeflow Jobs — a ferramenta de orquestração unificada para dados, analytics e IA — eles buscaram definir, gerenciar e monitorar mais facilmente jobs com várias tarefas para ETL, reduzir a intervenção manual e fornecer insights mais oportunos para melhorar a tomada de decisões.

## Unificando a orquestração de dados com Databricks Lakeflow Jobs

Com a Databricks Platform como parte central de sua infraestrutura de dados, o Databricks Lakeflow Jobs tornou-se essencial para resolver os desafios dos Reds, adaptando a orquestração para atender às suas necessidades específicas e integrando-se perfeitamente via APIs. Isso possibilitou trigger de jobs com parâmetros, permitindo maior controle do workflow. Os analistas ganharam independência para desenvolver e executar notebooks com rastreabilidade aprimorada e capacidades de processamento iterativo.

A equipe também adotou uma arquitetura serverless, o que reduziu significativamente a latência. Antes, usar job compute, mesmo com pools, frequentemente causava atrasos na espera de jobs serem inicializados.

"Com o Databricks Lakeflow Jobs serverless, alcançamos uma melhoria de 3 a 5 vezes na latência." O que antes levava 10 minutos, agora leva apenas 2 a 3 minutos, reduzindo significativamente o tempo de processamento. Isso nos permitiu oferecer ciclos de feedback mais rápidos para jogadores e treinadores, garantindo que eles obtenham os insights de que precisam quase em tempo real para tomar decisões acionáveis", disse Bryce.

Além dessa economia de tempo, a equipe observou uma redução de 65–80% nos custos de VM ao migrar para o Databricks Lakeflow Jobs serverless, tornando a solução não apenas mais rápida, mas também significativamente mais econômica. Com os Reds executando 15.000–20.000 etapas de workflow diariamente, essa eficiência economizou centenas de milhares de minutos de compute por dia, permitindo novos workloads e entrega mais rápida de relatórios.

A equipe fez a transição do Azure Data Factory para a Databricks. "Com a Databricks, transformamos completamente a forma como lidamos com dados. Mudar para uma arquitetura serverless e aproveitar o Databricks Lakeflow Jobs serverless não apenas simplificou nossos pipelines, mas também reduziu drasticamente a latência em até 83%", disse Bryce. "O que costumava levar uma hora agora pode ser feito em 10 minutos, o que nos permite executar mais processos, entregar relatórios com mais rapidez e fornecer feedback quase instantâneo para treinamento e desenvolvimento de jogadores. É um divisor de águas para a forma como tomamos decisões em tempo real em um esporte acelerado como o beisebol."

O ambiente serverless da plataforma removeu restrições relacionadas à memória e aos núcleos de compute. Isso permitiu que a equipe lidasse com queries de dados grandes e complexas de forma mais eficiente, resultando em insights mais rápidos e precisos para decisões no dia do jogo. A rastreabilidade dos workflows, desde a ingestão de dados até a saída final, também melhorou a responsabilidade, facilitando para a equipe monitorar, solucionar problemas e otimizar seus pipelines de dados. Cientistas e engenheiros de dados não enfrentam mais instabilidade do sistema, falhas na sessão ou longos tempos de processamento, permitindo workflows mais suaves e maior satisfação do job. Além disso, a natureza modular e automatizada do Databricks Lakeflow Jobs reduziu significativamente a sobrecarga dos desenvolvedores, liberando-os para se concentrarem em trabalhos de alto valor.

## Dados mais rápidos proporcionam decisões vencedoras de jogos

A transição para compute serverless reduziu significativamente a latência do job, reduzindo as etapas do pipeline de 10–15 minutos para apenas 2–3 minutos. Com o Databricks Lakeflow Jobs simplificando os processos, as tarefas de ETL e os fluxos de trabalho de ciência de dados agora operam com maior velocidade e agilidade.

Essa eficiência garante a rápida disponibilidade de dados, permitindo que os treinadores obtenham insights quase em tempo real para fazer ajustes críticos e fornecer feedback imediato aos jogadores.

"Com a Databricks, a economia de tempo que obtivemos é quase imensurável, permitindo coisas que não podíamos sequer considerar antes. Essa mudança alterou fundamentalmente a forma como operamos e a rapidez com que podemos entregar insights a treinadores, jogadores e analistas", concluiu Bryce. Essa mudança transformacional consolidou o Databricks Lakeflow Jobs como um facilitador crítico da estratégia de dados dos Reds, capacitando a equipe a tomar decisões mais inteligentes e rápidas no competitivo cenário do beisebol profissional.

**Conheça as melhores práticas de engenharia de dados e histórias de clientes no Big Book of Data Engineering (somente em inglês).**

## Ingerir, transformar e orquestrar com uma solução unificada de engenharia de dados

O Databricks Lakeflow foi desenvolvido para superar os principais desafios que as equipes de engenharia de dados enfrentam hoje. Como uma solução completa de engenharia de dados com inteligência de dados integrada, o Lakeflow unifica e simplifica a ingestão, transformação e orquestração de dados, oferecendo uma abordagem singular para a criação de pipelines de dados.

**Saiba mais** | **Assista à demonstração**

**Experimente a Databricks gratuitamente**

## Sobre a Databricks

A Databricks é a empresa de dados e IA. Mais de 15.000 organizações em todo o mundo, incluindo Block, Comcast, Condé Nast, Rivian, Shell e mais de 60% da Fortune 500, contam com a Databricks Data Intelligence Platform para controlar seus dados e utilizá-los com IA. A Databricks tem sede em São Francisco, com escritórios em todo o mundo, e foi fundada pelos criadores do Lakehouse, Apache Spark™, Delta Lake, MLflow e Unity Catalog. Para saber mais, siga a Databricks no LinkedIn, X e Facebook.

databricks

© Databricks 2025. Todos os direitos reservados. Apache, Apache Spark, Spark e o logotipo do Spark são marcas comerciais da Apache Software Foundation. Política de Privacidade | Termos de Uso